

# Изучение рынка заведений общественного питания Москвы

## Цель и задачи проекта

### Цель:

Провести исследовательский анализ данных заведений общественного питания Москвы для выбора подходящего инвесторам места для открытия собственного бизнеса.

### Задачи:

1. Загрузить данные и познакомиться с ними, сделать первые выводы о качестве данных
2. Предобработка данных с целью подготовки к исследовательскому анализу
3. Исследовательский анализ данных
4. Итоговые выводы и рекомендации для заказчика

## Описание данных

Файл `/datasets/rest_info.csv` содержит информацию о заведениях общественного питания:

- `name` — название заведения;
- `address` — адрес заведения;
- `district` — административный район, в котором находится заведение, например Центральный административный округ;
- `category` — категория заведения, например «кафе», «пиццерия» или «кофейня»;
- `hours` — информация о днях и часах работы;
- `rating` — рейтинг заведения по оценкам пользователей в Яндекс Картах (высшая оценка — 5.0);
- `chain` — число, выраженное 0 или 1, которое показывает, является ли заведение сетевым (для маленьких сетей могут встречаться ошибки): 0 — заведение не является сетевым; 1 — заведение является сетевым.
- `seats` — количество посадочных мест.

Файл `/datasets/rest_price.csv` содержит информацию о среднем чеке в заведениях общественного питания:

- `price` — категория цен в заведении, например «средние», «ниже среднего», «выше среднего» и так далее;
- `avg_bill` — строка, которая хранит среднюю стоимость заказа в виде диапазона, например: «Средний счёт: 1000–1500 ₽»; «Цена чашки капучино: 130–220 ₽»; «Цена бокала пива: 400–600 ₽». и так далее;
- `middle_avg_bill` — число с оценкой среднего чека, которое указано только для значений из столбца `avg_bill`, начинающихся с подстроки «Средний счёт»: Если в строке указан ценовой диапазон из двух значений, в столбец войдёт медиана этих двух значений. Если в строке

указано одно число — цена без диапазона, то в столбец войдёт это число. Если значения нет или оно не начинается с подстроки «Средний счёт», то в столбец ничего не войдёт.

- `middle_coffee_cup` — число с оценкой одной чашки капучино, которое указано только для значений из столбца `avg_bill`, начинающихся с подстроки «Цена одной чашки капучино»: Если в строке указан ценовой диапазон из двух значений, в столбец войдёт медиана этих двух значений. Если в строке указано одно число — цена без диапазона, то в столбец войдёт это число. Если значения нет или оно не начинается с подстроки «Цена одной чашки капучино», то в столбец ничего не войдёт.

## 1. Загрузка данных и знакомство с ними

Начнём с загрузки библиотек и данных о заведениях общественного питания Москвы. Путь к файлам: `/datasets/rest_info.csv` и `/datasets/rest_price.csv`. Будем использовать `pandas` и библиотеки визуализации данных `matplotlib` и `seaborn`, а также `phik` для построения матрицы корреляции. Данные датасетов сохраним в двух переменных: `info_df` и `price_df`.

Выгружаем данные в переменные `info_df` и `price_df`

Познакомимся с данными датасета `rest_info.csv` — выведем первые строки методом `head()`, а информацию о датафрейме методом `info()`:

|   | id                               | name                 | category | address                             | district                        |            |
|---|----------------------------------|----------------------|----------|-------------------------------------|---------------------------------|------------|
| 0 | 0c3e3439a8c64ea5bf6ecd6ca6ae19f0 | WoWфли               | кафе     | Москва, улица Дыбенко, 7/1          | Северный административный округ | ежед 10:00 |
| 1 | 045780ada3474c57a2112e505d74b633 | Четыре комнаты       | ресторан | Москва, улица Дыбенко, 36, корп. 1  | Северный административный округ | ежед 10:00 |
| 2 | 1070b6b59144425896c65889347fcff6 | Хазри                | кафе     | Москва, Клязьминская улица, 15      | Северный административный округ | 02:00      |
| 3 | 03ac7cd772104f65b58b349dc59f03ee | Dormouse Coffee Shop | кофейня  | Москва, улица Маршала Федоренко, 12 | Северный административный округ | ежед 09:00 |
| 4 | a163aada139c4c7f87b0b1c0b466a50f | Иль Марко            | пиццерия | Москва, Правобережная улица, 1Б     | Северный административный округ | ежед 10:00 |

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8406 entries, 0 to 8405
Data columns (total 9 columns):
#   Column      Non-Null Count  Dtype
---  -
0   id           8406 non-null   object
1   name         8406 non-null   object
2   category     8406 non-null   object
3   address      8406 non-null   object
4   district     8406 non-null   object
5   hours        7870 non-null   object
6   rating       8406 non-null   float64
7   chain        8406 non-null   int64
8   seats        4795 non-null   float64
dtypes: float64(2), int64(1), object(6)
memory usage: 591.2+ KB

```

Датасет `rest_info.csv` содержит 9 столбцов и 8406 строк, в которых представлена информация о заведениях общественного питания города Москва.

После первичного анализа данных можно сделать следующие выводы:

- Названия столбцов имеют один вид, понятны по значению и не требуют обработки.
- Представленные данные содержат строковые и числовые значения и хранятся в типах данных `object`, `int64` или `float64`. Значения в столбцах `id`, `name`, `category`, `address`, `district` и `hours` представлены строковыми данными и имеют в себе как текст, так и цифры. Значения в столбцах `rating`, `seats` числовые данные. Столбец `chain` имеет атрибуты признака и содержит значения 1 или 0 — размерность этих данных можно оптимизировать.
- Пропуски содержатся в столбцах `hours` - информация о времени работы и `seats` - количестве посадочных мест.
- Судя по первому знакомству с данными, значения в столбцах соответствуют своему описанию.

Теперь познакомимся с данными датасета `rest_price.csv`.

|   | id                               | price         | avg_bill                       | middle_avg_bill | middle_coffee_cup |
|---|----------------------------------|---------------|--------------------------------|-----------------|-------------------|
| 0 | 045780ada3474c57a2112e505d74b633 | выше среднего | Средний счёт: 1500–1600 ₽      | 1550.0          | NaN               |
| 1 | 1070b6b59144425896c65889347fcff6 | средние       | Средний счёт: от 1000 ₽        | 1000.0          | NaN               |
| 2 | 03ac7cd772104f65b58b349dc59f03ee | NaN           | Цена чашки капучино: 155–185 ₽ | NaN             | 170.0             |
| 3 | a163aada139c4c7f87b0b1c0b466a50f | средние       | Средний счёт: 400–600 ₽        | 500.0           | NaN               |
| 4 | 8a343546b24e4a499ad96eb7d0797a8a | средние       | NaN                            | NaN             | NaN               |

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4058 entries, 0 to 4057
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0   id                     4058 non-null  object
1   price                  3315 non-null  object
2   avg_bill               3816 non-null  object
3   middle_avg_bill        3149 non-null  float64
4   middle_coffee_cup      535 non-null   float64
dtypes: float64(2), object(3)
memory usage: 158.6+ KB
```

Датасет `price_info.csv` содержит 5 столбцов и 4058 строк, в которых представлена информация о среднем чеке в заведениях общественного питания.

После первичного анализа данных можно сделать следующие выводы:

- Названия столбцов имеют нужный вид, понятны по значению и не требуют обработки.
- Представленные данные содержат строковые и числовые значения и хранятся в типах данных `object` или `float64`. Значения в столбцах `id`, `price`, `avg_bill` представлены строковыми данными и имеют в себе как текст, так и цифры. Значения в столбцах `middle_avg_bill`, `middle_coffee_cup` числовые данные.
- Пропуски содержатся во всех столбцах, кроме `id`, что говорит о не очень хорошем качестве данных. Наиболее важными данными будут данные о средней цене из столбца `avg_bill`.
- Судя по первому знакомству с данными, значения в столбцах соответствуют своему описанию. Первичное знакомство с данными показало, что названия столбцов соответствуют установленной форме и содержание соответствует описанию. Тем не менее данные имеют пропуски с которыми нужно поработать.

## Подготовка единого датафрейма

Задача проекта предполагает анализ ценообразования в различных районах города, поэтому можно соединить данные о заведениях `info_df`, со средними ценами на товар из таблицы `price_df`.

Каждая строка в этих датафреймах — это информация о заведении, его расположении и ценах в этих заведениях, поэтому такие данные удобно соединить в один датафрейм, который можно использовать для поиска закономерностей в данных. Соединять данные будем по идентификатору заведения. При соединении оставим все данные о заведениях, даже если нет данных о ценах.

Соединим данные, используя значение параметра `how` — `'left'`. Это позволит оставить все данные по заведениям.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8406 entries, 0 to 8405
Data columns (total 13 columns):
#   Column                Non-Null Count  Dtype
---  -
0   id                    8406 non-null   object
1   name                  8406 non-null   object
2   category              8406 non-null   object
3   address               8406 non-null   object
4   district              8406 non-null   object
5   hours                 7870 non-null   object
6   rating                8406 non-null   float64
7   chain                 8406 non-null   int64
8   seats                 4795 non-null   float64
9   price                 3315 non-null   object
10  avg_bill              3816 non-null   object
11  middle_avg_bill       3149 non-null   float64
12  middle_coffee_cup     535 non-null    float64
dtypes: float64(4), int64(1), object(8)
memory usage: 853.9+ KB
```

|    | id                               | name                 | category        | address                                 | district                        |       |
|----|----------------------------------|----------------------|-----------------|-----------------------------------------|---------------------------------|-------|
| 0  | 0c3e3439a8c64ea5bf6ecd6ca6ae19f0 | WoWfli               | кафе            | Москва, улица Дыбенко, 7/1              | Северный административный округ |       |
| 1  | 045780ada3474c57a2112e505d74b633 | Четыре комнаты       | ресторан        | Москва, улица Дыбенко, 36, корп. 1      | Северный административный округ |       |
| 2  | 1070b6b59144425896c65889347fcff6 | Хазри                | кафе            | Москва, Клязьминская улица, 15          | Северный административный округ | г 11: |
| 3  | 03ac7cd772104f65b58b349dc59f03ee | Dormouse Coffee Shop | кофейня         | Москва, улица Маршала Федоренко, 12     | Северный административный округ |       |
| 4  | a163aada139c4c7f87b0b1c0b466a50f | Иль Марко            | пиццерия        | Москва, Правобережная улица, 1Б         | Северный административный округ |       |
| 5  | 8a343546b24e4a499ad96eb7d0797a8a | Sergio Pizza         | пиццерия        | Москва, Ижорская улица, вл8Б            | Северный административный округ |       |
| 6  | 96ebceb1a09e4e3191133b9fe0379a64 | Огни города          | бар,паб         | Москва, Клязьминская улица, 9, стр. 3   | Северный административный округ |       |
| 7  | 0243288b78024af090b8e947842c969c | Mr. Уголёк           | быстрое питание | Москва, Клязьминская улица, 9, стр. 3   | Северный административный округ | г 10: |
| 8  | 36aeb0ffa69c48fdb0021549520deb10 | Donna Maria          | ресторан        | Москва, Дмитровское шоссе, 107, корп. 4 | Северный административный округ |       |
| 9  | 487167877eb04288bc90d4fa80646fc2 | Готика               | кафе            | Москва, Ангарская улица, 39             | Северный административный округ |       |
| 10 | ac32978af97641bfacf996e7f5a50ee5 | Great Room Bar       | бар,паб         | Москва, Левобережная улица, 12          | Северный административный округ | кру   |
| 11 | 53ac103717c142f29907080db1f0ce58 | Шашлык Шефф          | кафе            | Москва, улица Маршала Федоренко, 10с1   | Северный административный округ |       |
| 12 | 9384a51a4b2749759234df689b3a4857 | Заправка             | кафе            | Москва, МКАД, 80-й километр, 1          | Северный административный округ | г     |

|    | id                               | name               | category | address                                  | district                        |     |
|----|----------------------------------|--------------------|----------|------------------------------------------|---------------------------------|-----|
| 13 | aea18265b0a0415893f1e796b82568fe | Буханка            | булочная | Москва, Базовская улица, 15, корп. 1     | Северный административный округ |     |
| 14 | b9469750090f4a19829cc717bc369988 | У Сильвы           | бар,паб  | Москва, Ангарская улица, 42с1            | Северный административный округ |     |
| 15 | 9b8421c55aef47efa4c6bc9e6fb4c239 | Дом обеда          | столовая | Москва, улица Бусиновская Горка, 2       | Северный административный округ | г   |
| 16 | ccda3acc54e34bfcac4d6a25a5205bcb | База Стритфуд      | кафе     | Москва, Базовская улица, 15, корп. 8     | Северный административный округ |     |
| 17 | b55465d0869648a295ad1d85ed9b5c4f | Чайхана Беш-Бармак | ресторан | Москва, Ленинградское шоссе, 71Б, стр. 2 | Северный административный округ | кру |
| 18 | 06e4244f6832490ea35c0c1f8824bb30 | Час-Пик            | столовая | Москва, Коровинское шоссе, 30А           | Северный административный округ |     |
| 19 | feec6bedccae44cb877d99c13f9aa5d7 | Пекарня            | булочная | Москва, Ижорский проезд, 5               | Северный административный округ | кру |
| 20 | 1ab5691e4da844d3abadf085e0957852 | Чебуреки Манты     | кафе     | Москва, Правобережная улица, 1Б          | Северный административный округ |     |
| 21 | 3483fb839c134fc89e15a1da83053498 | 7/12               | кафе     | Москва, Прибрежный проезд, 7             | Северный административный округ |     |
| 22 | 66274ec5b26440e389aa3584b5cc2e9c | Крымские чебуреки  | кафе     | Москва, Коровинское шоссе, 35, стр. 17   | Северный административный округ | г   |
| 23 | 78709462f2b3480f825489a5321a3563 | Буханка            | булочная | Москва, Лобненская улица, 13к2           | Северный административный округ |     |
| 24 | 0f5d22f5377340d0a81a9328e6ebdcac | Drive Café         | кафе     | Москва, улица Дыбенко, 9Ас1              | Северный административный округ | кру |

Данные соединились с сохранением информации по всем заведениям общественного питания.

|                   |       |
|-------------------|-------|
| middle_coffee_cup | 7871  |
| middle_avg_bill   | 5257  |
| price             | 5091  |
| avg_bill          | 4590  |
| seats             | 3611  |
| hours             | 536   |
| district          | 0     |
| category          | 0     |
| name              | 0     |
| id                | 0     |
| address           | 0     |
| chain             | 0     |
| rating            | 0     |
| dtype:            | int64 |



```

id                0.000000
name              0.000000
category          0.000000
address           0.000000
district          0.000000
hours             0.063764
rating            0.000000
chain             0.000000
seats             0.429574
price             0.605639
avg_bill          0.546039
middle_avg_bill   0.625387
middle_coffee_cup 0.936355
dtype: float64

```

В датафрейме `df` обнаружено:

- 536 пропусков в столбце `hours` — это 6 % данных. Это информация о времени работы. Количество пропусков небольшое, их можно просто удалить.
- 3611 пропусков в столбце `seats` - это 43 % данных. В нем содержится информация о количестве посадочных мест. Пропуски в этом столбце могут быть вызваны:
  - Не занесены данные в сервисе Яндекс Бизнес.
  - При обработке данных произошёл технический сбой. Технические ошибки могут привести к пропускам в данных, включая случаи, когда количество мест не было записано.
  - Возможно количество пропусков связано стипом заведения, в некоторых типах заведений , например "еда на вынос" или "булочная" просто нет посадочных мест. Можно проверить эту гипотезу, если проанализировать значения в столбцах `category` и `seats` в строках с пропусками.
- 5091 пропусков в столбце `price` - это 60 % данных. Возможные причины пропусков:
  - Не занесены данные в сервисе Яндекс Бизнес.
  - Возможно некоторые заведения не имеют четкого распределения цены на категории, оставим как есть.
- 4590 пропусков в столбце `avg_bill` , в котором хранится средняя стоимость заказа в виде диапазона значений - это 55 % данных. Оставим данные без изменения, так как они не участвуют в дальнейшем анализе.
- 5257 пропусков в столбце `middle_avg_bill` что составляет 63% от общего количества строк. В нем храниться информация о среднем чеке. Причина пропусков:
  - основная причина это зависимость от предыдущего столбца `avg_bill` , в котором 4590 пропусков, кроме этого в него попадают данные только с подстрокой "Средний счет" из столбца `avg_bill` . -7871 пропусков в столбце `middle_coffee_cup` , что составляет 94 % пропусков. Причина в том, что здесь данные только по средней цене кофе, и только из заполненных ячеек `avg_bill` . Эти данные не будут участвовать в анализе, поэтому оставим их без изменения.

Проверка гипотезы зависимости пропусков в столбце `seats` в зависимости от категории заведения

Количество уникальных категорий: 8

Уникальные категории:

- кафе
- ресторан
- кофейня
- пиццерия
- бар, паб
- быстрое питание
- булочная
- столовая

Категория: кафе

- Всего заведений: 2378
- Пропуски в seats: 1160 (48.8%)

Категория: ресторан

- Всего заведений: 2043
- Пропуски в seats: 773 (37.8%)

Категория: кофейня

- Всего заведений: 1413
- Пропуски в seats: 662 (46.9%)

Категория: пиццерия

- Всего заведений: 633
- Пропуски в seats: 206 (32.5%)

Категория: бар, паб

- Всего заведений: 765
- Пропуски в seats: 297 (38.8%)

Категория: быстрое питание

- Всего заведений: 603
- Пропуски в seats: 254 (42.1%)

Категория: булочная

- Всего заведений: 256
- Пропуски в seats: 108 (42.2%)

Категория: столовая

- Всего заведений: 315
- Пропуски в seats: 151 (47.9%)

Из проведенного исследования видим, что наша гипотеза не подтвердилась и количество мест практически не зависит от типа заведения. Значить это скорее всего пропуски связанные с отсутствием информации в сервисе Яндекс Бизнес или техническим сбоем.

Проверим пропуски в столбце `price` и заменим их на "цена не определена".

Количество уникальных категорий: 4

Уникальные категории:

- nan
- выше среднего
- средние
- высокие
- низкие

Результаты заполнения:

Статистика по столбцу price после заполнения:

price

цена не определена 5091

средние 2117

выше среднего 564

высокие 478

низкие 156

Name: count, dtype: int64

Количество пропусков: 0

В результате проделанной работы пропуски заменены на значение "цена не определена".

## 2.3. Явные и неявные дубликаты в данных

Проверим данные на наличие явных и неявных дубликатов. Начнём с полных дубликатов:

```
np.int64(0)
```

В датафрейме нет полных дубликатов. Проверим неявные дубликаты — значения по `id` заведений должны быть уникальными и указывать на отдельное заведение питания.

```
np.int64(0)
```

В этом случае все хорошо, дубликатов нет.

```
np.int64(2792)
```

А вот в названии дубликаты есть, нужно проанализировать причину появления дубликатов, возможно это названия сетевых заведений.

Всего записей с дублирующимися названиями: 2792  
Процент от общего числа: 33.2%  
Уникальных названий: 5614  
Всего записей: 8406

Названий с дубликатами: 714

Топ-10 самых частых дубликатов:

|                  |     |
|------------------|-----|
| name             |     |
| Кафе             | 188 |
| Шоколадница      | 119 |
| Домино'с Пицца   | 75  |
| Додо Пицца       | 73  |
| One Price Coffee | 70  |
| Яндекс Лавка     | 68  |
| Cofix            | 64  |
| Prime            | 49  |
| Хинкальная       | 43  |
| Шаурма           | 42  |

Name: count, dtype: int64

Скорее всего эти заведения являются либо сетевыми, либо просто имеют одинаковое название, но это разные заведения.

## 2.5. Промежуточные выводы после предобработки

На этом предобработка завершена. Предоставленные данные не очень хорошего качества и требовали определенных действий по предобработке. Отметить основные действия и ошибки, с которыми мы столкнулись на этом шаге.

В результате предобработки данных были выполнены следующие действия:

- Изучены пропуски в данных. Пропуски обнаружались в столбцах `hours` их немного, оставили без изменений; `seats` составляют 43 % данных столбца, оставили без изменений; в столбце `price` 60 % отсутствующих данных, заменили на "цена не определена"; в столбце `avg_bill` - 55 % пропусков, в `middle_avg_bill` 63% пропусков и `middle_coffee_cup` -94 % пропусков - эти пропуски оставлены без изменений. Учитывая количество пропусков можно сделать вывод о неполных данных и возможных неточностях при дальнейшем анализе, пропуски могут отражать особенности заполнения сервисов Яндекс Бизнес и Яндекс Карты носящих справочный характер. Поэтому их оставили как есть.
- Данные проверили на явные и неявные дубликаты — дубликаты встретились только в названии заведений, оказалось что это сетевые заведения или разные заведения с одинаковым названием.

## 3. Исследовательский анализ данных


### 3.1. Исследуем категории заведений

Как уже выяснили из предварительного анализа всего уникальных категорий заведений 8. Посмотрим какое количество заведений находится в каждой категории и визуализируем с помощью столбчатой диаграммы.

Распределение заведений по значениям столбца category:

|                 | count | percentage |
|-----------------|-------|------------|
| category        |       |            |
| кафе            | 2378  | 28.29      |
| ресторан        | 2043  | 24.30      |
| кофейня         | 1413  | 16.81      |
| бар, паб        | 765   | 9.10       |
| пиццерия        | 633   | 7.53       |
| быстрое питание | 603   | 7.17       |
| столовая        | 315   | 3.75       |
| булочная        | 256   | 3.05       |

Распределение категорий в зависимости от количества заведений в них



Из исследования стало понятно, что наибольшее количество заведений является кафе -2378, что составляет 28 %, немного меньше рестораны-2043 (24 %)и кофейни-1413 (17%), остальные категории занимают наименьшую часть, каждая менее 10 %.

**3.2. Исследуем административные районы города Москва и заведения в них. Отдельно уделим внимание Центральному округу Москвы и определим категории заведений в нем.**

Распределение заведений по значениям столбца district:

|                                         | count | percentage |
|-----------------------------------------|-------|------------|
| district                                |       |            |
| Центральный административный округ      | 2242  | 26.67      |
| Северный административный округ         | 900   | 10.71      |
| Южный административный округ            | 892   | 10.61      |
| Северо-Восточный административный округ | 891   | 10.60      |
| Западный административный округ         | 851   | 10.12      |
| Восточный административный округ        | 798   | 9.49       |
| Юго-Восточный административный округ    | 714   | 8.49       |
| Юго-Западный административный округ     | 709   | 8.43       |
| Северо-Западный административный округ  | 409   | 4.87       |




Из анализа видно, что наибольшее количество заведений именно в Центральном округе Москвы 2242, что составляет 27 % от общего количества. Почти треть заведений.

Распределение заведений по категориям в Центральном административном округе:

|                 | count | percentage |
|-----------------|-------|------------|
| category        |       |            |
| ресторан        | 670   | 29.88      |
| кафе            | 464   | 20.70      |
| кофейня         | 428   | 19.09      |
| бар, паб        | 364   | 16.24      |
| пиццерия        | 113   | 5.04       |
| быстрое питание | 87    | 3.88       |
| столовая        | 66    | 2.94       |
| булочная        | 50    | 2.23       |

## Распределение категорий заведений в Центральном административном округе



Из проведенного анализа видно, что в Центральном округе больше всего ресторанов - 670 (30%), потом уже кафе - 464 (21%) и кофейни - 428 (19%).


### 3.3. Исследуем соотношение сетевых и не сетевых заведений и распределение их по категориям.

Распределение сетевых и не сетевых заведений в Москве

|       | count | percentage |
|-------|-------|------------|
| chain |       |            |
| 0     | 5201  | 61.87      |
| 1     | 3205  | 38.13      |

Text(0.5, 1.0, 'Распределение количества сетевых и несетевых заведений')


## Распределение количества сетевых и несетевых заведений



Как мы видим количество несетевых заведений значительно больше чем сетевых 62 % против 38%.



Распределение категорий в зависимости от вида сетевое или нет



|   | Категория       | Всего заведений | Сетевые | Несетевые | % сетевых |
|---|-----------------|-----------------|---------|-----------|-----------|
| 0 | бар,паб         | 765             | 169     | 596       | 22.1%     |
| 1 | булочная        | 256             | 157     | 99        | 61.3%     |
| 2 | быстрое питание | 603             | 232     | 371       | 38.5%     |
| 3 | кафе            | 2378            | 779     | 1599      | 32.8%     |
| 4 | кофейня         | 1413            | 720     | 693       | 51.0%     |
| 5 | пиццерия        | 633             | 330     | 303       | 52.1%     |
| 6 | ресторан        | 2043            | 730     | 1313      | 35.7%     |
| 7 | столовая        | 315             | 88      | 227       | 27.9%     |



Распределение принадлежности к сети по категориям говорит нам о том, что в категориях булочная 61%, пиццерия 52% , кофейня 51% преобладает сетевая форма заведений, в остальных категориях заведений больше несетевых заведений

### 3.4. Исследуем количество посадочных мест в заведениях.

Посмотрим встречаются ли аномальные значения, или выбросы. Приведем для каждой категории заведений типичное количество мест. Визуализируем эти данные.

Статистические показатели столбца seats:

```
count    4795.000000
mean      108.421689
std       122.833396
min        0.000000
25%       40.000000
50%       75.000000
75%      140.000000
95%      307.000000
99%      625.000000
max      1288.000000
Name: seats, dtype: float64
```



Распределение количества мест асимметричное, скошенное вправо. Минимальное количество мест — 0, а максимальное — 1278, что является не вполне корректным. Среднее значение соответствует 108 местам, тогда как медиана — 75 мест. Среднее и медианное значение далеки друг от друга, что говорит о выбросе данных с большим количеством мест, так как 99 перцентиль всего 625 мест, а максимальное значение 1278. По гистограмме размаха видно, что значения выше примерно 300 мест можно считать выбросами.

При анализе данных отбросим значения более 99 перцентилья, это 625 мест. Потому что значения больше этого единичны и сильно исказят картину анализа.


```
count    4742.000000
mean      100.420919
std       92.901015
min        0.000000
25%       40.000000
50%       74.000000
75%      130.000000
max       600.000000
Name: seats, dtype: float64
```

Ситуация немного улучшилась, среднее 100 мест и медиана 74 места приблизились друг к другу. Исключилось из выборки 53 заведения.

Медианное количество посадочных мест для каждой категории заведений category:

```
category
ресторан      86.0
бар, паб      80.0
кофейня       78.0
столовая      75.0
быстрое питание 65.0
кафе          60.0
пиццерия      52.0
булочная     50.0
Name: seats, dtype: float64
```

Распределение категорий в зависимости от медианного количества посадочных мест в них



Из таблицы и графика мы видим как распределяется медианное значение по количеству посадочных мест, что показывает типичное количество мест в заведениях в зависимости от категории.

### 3.5. Исследуем рейтинг заведений.

Распределим средние значения рейтингов по категориям заведений, посмотрим расброс значений. Построим визуализацию


Общая статистика по рейтингу:

```
count    8406.000000
mean      4.229895
std       0.470348
min       1.000000
1%        2.300000
25%       4.100000
50%       4.300000
75%       4.400000
99%       5.000000
max       5.000000
Name: rating, dtype: float64
```

- Среднее значение (4.23) близко к максимуму (5.0)
- 75% заведений имеют рейтинг  $\geq 4.1$
- Медиана (4.3) выше среднего, что указывает на левостороннюю асимметрию
- Стандартное отклонение (0.47) относительно небольшое
- Вывод: Данные достаточно однородны (большая часть находится в узком диапазоне от 4 до 5)

Средний рейтинг для каждой категории заведений category:

```
category
бар, паб      4.387712
пиццерия      4.301264
ресторан      4.290357
кофейня       4.277282
булочная     4.268359
столовая      4.211429
кафе          4.123886
быстрое питание 4.050249
Name: rating, dtype: float64
```



Из проведенного исследования распределения рейтинга заведений в зависимости от категории видно, что разброс значений между категориями минимальный от 4, до 4,4 балла. Поэтому здесь трудно выделить наиболее популярные категории заведений. Наибольший рейтинг 4,4 балла у баров(пабов).

### 3.6. Изучим корреляцию данных с рейтингом заведения

Построим матрицу корреляции рейтинга в зависимости от категории, расположения, статуса сетевого заведения, количеством мест, ценовой категорией, круглосуточностью.

```
interval columns not set, guessing: ['chain', 'seats', 'is_24_7', 'rating']
Корреляционная матрица с коэффициентом phi_k для переменной rating
```


|          | rating   |
|----------|----------|
| price    | 0.281294 |
| district | 0.200691 |
| category | 0.190003 |
| is_24_7  | 0.144762 |
| chain    | 0.108092 |
| seats    | 0.000000 |

Наибольшая корреляция рейтинга заведений наблюдается с ценовой категорией (  $0.29$  ). Для остальных признаков коэффициент корреляции снижается с  $0.2$  до  $0$  .

Важно помнить, что `phi_k` сообщает только о наличии связи между данными. На сам характер связи коэффициент `phi_k` не указывает, поэтому после получения коэффициента следует продолжить анализ. Например, можно предположить, что увеличение ценовой категории отрицательно связано с рейтингом — чем выше категория цен, тем меньше рейтинг. Такую гипотезу можно проверить при анализе данных.

Перед тем как перейти к дальнейшему анализу, визуализируем результат корреляции с помощью тепловой карты и библиотеки `seaborn`:

## Тепловая карта коэффициента $\phi_k$ для данных rating




Теперь оценим зависимость рейтинга от ценовой категории

Средний рейтинг для каждой категории цен price:

```
price
высокие          4.436611
выше среднего    4.386348
средние          4.297874
низкие           4.173077
цена не определена 4.166627
Name: rating, dtype: float64
```

Распределение категории цен в зависимости от среднего рейтинга



Из построенных визуализаций видим что наше предположение не подтвердилось, а наоборот заведения с более высокой ценой имеют более высокий рейтинг. Хотя разница в значениях минимальна.

### 3.7. Сгруппируем данные по названиям заведений и найдем топ-15 популярных сетей в Москве.

Для них рассчитаем значение среднего рейтинга и определим к какой категории заведений они относятся.


```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8406 entries, 0 to 8405
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   id                    8406 non-null  object
1   name                  8406 non-null  object
2   category              8406 non-null  object
3   address               8406 non-null  object
4   district              8406 non-null  object
5   hours                 7870 non-null  object
6   rating                8406 non-null  float64
7   chain                 8406 non-null  int8
8   seats                 4795 non-null  float64
9   price                 8406 non-null  object
10  avg_bill              3816 non-null  object
11  middle_avg_bill       3149 non-null  float64
12  middle_coffee_cup     535 non-null   float64
13  is_24_7               8406 non-null  int64
dtypes: float64(4), int64(1), int8(1), object(8)
memory usage: 862.1+ KB
```



|   | id                               | name                       | category | address                                   | district                              |               |
|---|----------------------------------|----------------------------|----------|-------------------------------------------|---------------------------------------|---------------|
| 0 | 0c3e3439a8c64ea5bf6ecd6ca6ae19f0 | WoWfli                     | кафе     | Москва, улица<br>Дыбенко, 7/1             | Северный<br>административный<br>округ | ежед<br>10:00 |
| 1 | 045780ada3474c57a2112e505d74b633 | Четыре<br>комнаты          | ресторан | Москва, улица<br>Дыбенко, 36,<br>корп. 1  | Северный<br>административный<br>округ | ежед<br>10:00 |
| 2 | 1070b6b59144425896c65889347fcff6 | Хазри                      | кафе     | Москва,<br>Клязьминская<br>улица, 15      | Северный<br>административный<br>округ | 02:0<br>0     |
| 3 | 03ac7cd772104f65b58b349dc59f03ee | Dormouse<br>Coffee<br>Shop | кофейня  | Москва, улица<br>Маршала<br>Федоренко, 12 | Северный<br>административный<br>округ | ежед<br>09:00 |
| 4 | a163aada139c4c7f87b0b1c0b466a50f | Иль<br>Марко               | пиццерия | Москва,<br>Правобережная<br>улица, 1Б     | Северный<br>административный<br>округ | ежед<br>10:00 |

Топ-15 сетей с количеством филиалов и средним рейтингом:

|                                     | name             | avg_rating | branch_count |
|-------------------------------------|------------------|------------|--------------|
|                                     | Шоколадница      | 4.18       | 120          |
|                                     | Домино'с Пицца   | 4.17       | 76           |
|                                     | Додо Пицца       | 4.29       | 74           |
|                                     | One Price Coffee | 4.06       | 71           |
|                                     | Яндекс Лавка     | 3.87       | 69           |
|                                     | Cofix            | 4.08       | 65           |
|                                     | Prime            | 4.12       | 50           |
|                                     | Хинкальная       | 4.32       | 44           |
|                                     | КОФЕПОРТ         | 4.15       | 42           |
| Кулинарная лавка братьев Караваевых |                  | 4.39       | 39           |
|                                     | Теремок          | 4.12       | 38           |
|                                     | Чайхана          | 3.92       | 37           |
|                                     | CofeFest         | 3.98       | 32           |
|                                     | Буханка          | 4.40       | 32           |
|                                     | Му-Му            | 4.23       | 27           |



Из проведенного исследования можно сделать следующие выводы: Среди сетевых заведений самыми популярными является Шоколадница - 120 филиал, с рейтингом 4,18. В отстающих Му-МУ - 27 филиалов, но его рейтинг - 4,23. Самый высокий рейтинг у Буханки - 4,4, но количество филиалов всего - 32.

Распределение заведений топ-15 сетей по категориям:

| category        | count | percentage |
|-----------------|-------|------------|
| кофейня         | 336   | 41.2       |
| ресторан        | 186   | 22.8       |
| пиццерия        | 151   | 18.5       |
| кафе            | 100   | 12.3       |
| булочная        | 25    | 3.1        |
| быстрое питание | 12    | 1.5        |
| бар, паб        | 4     | 0.5        |
| столовая        | 2     | 0.2        |



По категориям самыми популярными заведениями считаются кофейни -41 %, с большим отставанием идут рестораны- 23% , пиццерии- 19 % Наименьшее количество в категории бары(пабы) и столовые - менее 1 процента.

### 3.8. Изучим вариацию среднего чека заведений в зависимости от районов Москвы.

Проанализируем цены в Центральном округе и остальных, посмотрим как удаленность влияет на цену.

Средняя цена для каждого округа Москвы district:

```
district
Центральный административный округ    1191.057547
Западный административный округ        1053.225490
Северный административный округ         927.959627
Южный административный округ            834.398089
Северо-Западный административный округ  822.222930
Восточный административный округ        820.626923
Юго-Западный административный округ     792.561702
Северо-Восточный административный округ 716.611296
Юго-Восточный административный округ    654.097938
Name: middle_avg_bill, dtype: float64
```



Так как административные округа Москвы распределены географически по кругу, а в центре - Центральный административный округ, то судить об удаленности того или иного округа от центра не корректно. Из проведенного исследования видим, что в Центральном административном округе средняя цена наибольшая и составляет примерно 1191 рубль. В остальных округах цены ниже, наименьшая в Юго- Восточном это 654 рубля. Наибольшая в Западном округе. - 1053 рубля.

### 3.9. Промежуточные выводы после исследования.

В результате проведенных исследований мы выяснили какие категории заведений имеются и их количество, получилось 8 категорий, самая популярная кафе-2378 заведений, что составляет 28 %.

- Выяснили сколько административных округов представлено в данных их 9, больше всего заведений в Центральном округе 2242 это 27 %, его мы изучили более детально и выяснили, что больше всего в нем ресторанов -670 (30%).
- Среди сетевых и не сетевых форм преобладает не сетевая с количеством заведений 5201 (62%) против 3205 (38%) сетевых. Среди сетевых наиболее популярны категории: булочная 61%, пиццерия 52%, кофейня 51% заведений.
- Исследовав количество посадочных мест в заведениях нашли нетипичные значения в диапазоне более 600 мест и отфильтровали данные до 600 мест. Наибольшее количество мест в ресторанах.
- По рейтингу разница между категориями очень мала, тем не менее заведения выстроились следующим образом: верхние строчки занимают бары(пабы), пиццерии и рестораны.
- Изучая взаимосвязь данных выяснили что самая большая корреляция между рейтингом и категорией цен, изучив ее более подробно пришли к выводу что, наибольший рейтинг у заведений с наибольшей ценовой категорией.

- Нашли топ 15 самых популярных сетей в Москве, первую строчку занимает сеть Шоколадница -120 филиалов со средним рейтингом 4,18. Наибольший рейтинг имеет сеть Буханка - 4,4 состоит из 32 филиалов.
  - Как и ожидалось самые высокие цены в Центральном округе Москвы, в остальных округах они тоже отличаются и самым "дорогим" после центрального является Западный административный округ.
- 

## Итоговый вывод и рекомендации

В ходе исследования было проанализировано 8406 заведений общественного питания Москвы. Хотя данные и были не полными, потому-что взяты из открытых источников, они включали в себя названия, адреса, месторасположение (административный округ), категорию, время работы, рейтинг, принадлежность к сети, количество посадочных мест, категории цен, средние цены. Основной акцент исследования был сделан на изучение популярности заведений по их категориям и месту расположения в городе Москва.

## Наиболее популярные заведения

Из общего количества заведений 8406, самые популярные это кафе их в Москве 2378, что составляет 28 % от всех заведений . В Центральном округе больше всего заведений питания 2242 и в них преобладают рестораны 670 - 30% . Эти категории заведений в большей своей части являются не сетевыми. Рейтинг имеют примерно одинаковый. Если посмотреть на заведения принадлежащие к сети, то среди них самые популярные Шоколадница имеет 120 филиалов и принадлежит к самой популярной категории среди сетевых -кофейня. Рейтинг у нее 4,18.

## Рекомендации

Основная цель нашего исследования проанализировать данные заведений общественного питания и дать рекомендации заказчику по вариантам открытия собственного бизнеса в этой сфере.

Исходя из этого можем предположить некоторые варианты:

1. Если заведение будет не сетевым, то наилучшим вариантом мы видим в Центральном округе это ресторан, в остальной части Москвы кафе.
  2. Если заведения будет принадлежать к сети, то возможно это будет кофейня Шоколадница, они самые популярные.
- Многое будет зависеть от стартовых возможностей заказчика.